

LLM-driven Ontology Construction for Bioprocesses

*Construcción de ontologías para bioprocesos
impulsada por modelos de lenguaje.*

Integrantes:

Anderson Daniel Pipicano Ruiz

Sandra Jimena Orozco Lagos

Tutor: Jairo Alexander Astudillo Lagos (INRAe)

Contexto y motivación

El reto no es solo describir biorreactores: es hacer comparables sus conceptos entre escalas.

Micro/mini

Alta paralelización
BioLector XT

Laboratorio

Control y operación
Biostat / UniVessel

Piloto

Transición de escala
parámetros
comparables

Industrial

Producción
robustez y control

Heterogeneidad

Variables, sensores, actuadores
y terminología cambian entre
sistemas.

Interoperabilidad

Se requiere una representación
común que pueda ser leída por
humanos y máquinas.

Trazabilidad

Cada afirmación debe
conectarse con evidencia
documental verificable.

Problema y objetivo de investigación

Problema central

La información sobre biorreactores multiescala está distribuida en documentos técnicos y científicos, con diferencias de terminología, instrumentación y nivel de detalle.

Esto dificulta comparar sistemas, reutilizar conocimiento y mapear variables equivalentes entre escalas.

Objetivo documentado

Desarrollar una ontología multiescala de bioprocesos para biorreactores micro/mini, laboratorio, piloto e industrial, usando al menos tres LLMs como asistentes.


Objetivos específicos:

- Definir alcance y preguntas de competencia;
- Generar ontologías candidatas por LLM;
- Armonizar conceptos, relaciones y terminología;
- Modelar escala, sensores, actuadores y equivalencias;
- Validar con expertos.

Estado del proyecto: avance parcial de investigación


Fundamentos conceptuales

- Ontología: modelo explícito de clases, relaciones y restricciones del dominio.
- OWL/RDF: formalización mediante clases, propiedades y triadas sujeto–predicado–objeto.
- Preguntas de competencia: delimitan qué debe poder responder la ontología.
- Corpus curado: evidencia documental que evita construir relaciones sin soporte.
- LLMs: asistentes para generar candidatos, no fuentes de verdad.



Regla metodológica: si la evidencia es insuficiente, se declara como no establecido en el corpus

Metodología LLM-driven propuesta



Realizado / evidenciado

Prompts, preguntas ALC-01 a ALC-08, paquetes de corpus, respuestas y CSV por LLM.

En curso


Comparación entre salidas, deduplicación, normalización terminológica y revisión de consistencia.

Pendiente

Formalización OWL final, pruebas de coherencia y validación experta de dominio.


Principio de diseño: mismas condiciones de prompting y corpus para comparar los tres LLMs.

Modelo conceptual multiescala



Equivalencias funcionales entre escalas: candidatas y sujetas a validación

Estrategia de comparación entre LLMs



- Se extraen conceptos, relaciones y triadas RDF candidatas.
- Se conservan evidencia, fuente, confianza y necesidad de validación.
- La comparación busca solapamientos, contradicciones y variantes terminológicas.
- La consolidación final aún requiere formalización OWL y revisión experta.

Alcance ontológico definido

BioLector XT

Micro/mini escala
screening y alta
paralelización

Sartorius 5 L

Escala laboratorio
desarrollo y optimización

Sartorius 10 L

Transición lab–piloto
validación de
escalamiento

Incluye

- tipos de biorreactor
- variables de operación
- sensores y actuadores
- fases del proceso
- eventos asociados
- equivalencias entre escalas


Excluye por ahora

- modelado cinético detallado
- recuperación y purificación
- descripción molecular exhaustiva
- evaluación económica
- control automático avanzado

Criterio de diseño: primera versión clara, viable y centrada en el bioproceso dentro del biorreactor

Preguntas: de alcance a validación


Las preguntas se reorganizan en cinco niveles para guiar el proceso ontológico de forma trazable.



Salida clave: matriz pregunta → fuente documental → conceptos → relaciones → triadas → decisión OWL → validación

Criterios de evaluación

La decisión multicriterio pondera desempeño ontológico y viabilidad práctica.



Nota: criterios y pesos definidos en la presentación de avance; deben mantenerse como evaluación preliminar.

Modelos seleccionados y función

La combinación permite comparar rendimiento, apertura y comportamiento de arquitecturas diferentes.

GPT-4o

Modelo de referencia

Alto rendimiento para planificación y extracción condicionada.

LLaMA-3

Modelo open-source

Ajustable y viable para múltiples iteraciones académicas.

Claude Sonnet

Modelo complementario

Arquitectura diferenciada para detectar discrepancias sistemáticas.

Uso previsto: mismo corpus + mismo prompt + comparación de conceptos, relaciones y triadas candidatas

Avances parciales alcanzados

Alcance y preguntas	ALC-01 a ALC-08 organizadas por LLM	Realizado
Corpus y paquetes	corpus_planning.md y corpus_extraction_package.md	Realizado
Extracción asistida	respuestas corpus.md y estructuras corpus.csv	Realizado
Comparación LLMs	carpetas Llama_3, GPT-4o y Claude_Sonnet	En curso
OWL final validada	no se identifica como entregable cerrado en los archivos revisados	Pendiente
Validación experta	marcada como necesaria en varias salidas candidatas	Pendiente

Lectura del avance: se cuenta con insumos trazables, pero la ontología consolidada aún está en construcción

Ejemplos -> preguntas y triadas candidatas

Pregunta ALC-01

¿Qué se entiende por biorreactor dentro del proyecto?
Evidencia: BioLector XT, Biostat B y UniVessel Glass con referencias a SRC-004 p.2 y SRC-005 p.8.

Triada candidata 1

UnivesselGlass → hasAvailableWorkingVolume → "5 L" / "10 L"
Fuente: UniVessel® Glass, p.8. Estado: explícita.

Triada candidata 2

BiostatB → regulatesParameter → pH / DO / StirrerSpeed
Evidencia: "Control temperature, pH, DO, stirrer speed".
Fuente: Biostat® B, p.22.

Triada candidata 3

BioLectorXT → monitorsVariable → Biomass / pH / DO / Fluorescence
Evidencia: monitoreo en línea registrado en SRC-003, páginas 1–3. Estado: soportada.

Trazabilidad mínima conservada: pregunta/triada · evidencia · fuente · página/ubicación · estado

Limitaciones y riesgos metodológicos

Cobertura del corpus

Puede dejar fuera documentos técnicos o SOPs relevantes.

Calidad de evidencia

No toda afirmación tiene página o fragmento completo.

Variabilidad entre LLMs

Modelos diferentes pueden proponer relaciones distintas.

Alucinaciones

Se mitiga obligando a declarar lo no establecido.

Heterogeneidad terminológica

pH, DO, optodos, control y monitoreo deben normalizarse.

Validación experta

Necesaria para equivalencias, inferencias y decisiones OWL.

Criterio de calidad: cada relación consolidada debe mantener evidencia, fuente, estado y decisión de modelado

Conclusiones y trabajo futuro

Conclusiones parciales

- El proyecto ya cuenta con una metodología LLM-driven trazable.
- El repositorio evidencia preguntas ALC, corpus y salidas candidatas por LLM.
- La ontología final aún debe consolidarse, formalizarse y validarse.

Próximos pasos verificables

1. Consolidar ontologías candidatas.
2. Formalizar clases y propiedades en OWL/RDF.
3. Validar con expertos de dominio.
4. Ejecutar pruebas de coherencia.
5. Documentar decisiones de modelado.
6. Construir la versión final de la ontología.

Referencias

- Abolhasani, M. S. (n.d.). *Leveraging LLM for Automated Ontology Extraction and Knowledge Graph Generation*.
- Bai, J., Mosbach, S., Taylor, C. J., Karan, D., Lee, K. F., Rihm, S. D., Akroyd, J., Lapkin, A. A., & Kraft, M. (2024). A dynamic knowledge graph approach to distributed self-driving laboratories. *Nature Communications*, 15(1). <https://doi.org/10.1038/s41467-023-44599-9>
- Chen, J., Xu, X., Liu, J., Gao, Y., Guo, J., Ding, Z., Zhang, M., Zhu, J., & He, Y. (2026). Ontology-Driven Automatic Scoring of Mechanization Rate in Power Grid Construction Projects Using Large Language Models. *Buildings*, 16(5). <https://doi.org/10.3390/buildings16051010>
- Fathallah, N., Staab, S., & Algergawy, A. (2024a). *LLMs4Life: Large Language Models for Ontology Learning in Life Sciences*. <http://arxiv.org/abs/2412.02035>
- Fathallah, N., Staab, S., & Algergawy, A. (2024b). *LLMs4Life: Large Language Models for Ontology Learning in Life Sciences*. <http://arxiv.org/abs/2412.02035>
- Manda, P. (2025a). Large Language Models in Bio-Ontology Research: A Review. In *Bioengineering* (Vol. 12, Number 11). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/bioengineering12111260>
- Manda, P. (2025b). Large Language Models in Bio-Ontology Research: A Review. In *Bioengineering* (Vol. 12, Number 11). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/bioengineering12111260>
- Val-Calvo, M., Egaña Aranguren, M., Mulero-Hernández, J., Almagro-Hernández, G., Deshmukh, P., Bernabé-Díaz, J. A., Espinoza-Arias, P., Sánchez-Fernández, J. L., Mueller, J., & Fernández-Breis, J. T. (2025a). OntoGenix: Leveraging Large Language Models for enhanced ontology engineering from datasets. *Information Processing and Management*, 62(3). <https://doi.org/10.1016/j.ipm.2024.104042>
- Val-Calvo, M., Egaña Aranguren, M., Mulero-Hernández, J., Almagro-Hernández, G., Deshmukh, P., Bernabé-Díaz, J. A., Espinoza-Arias, P., Sánchez-Fernández, J. L., Mueller, J., & Fernández-Breis, J. T. (2025b). OntoGenix: Leveraging Large Language Models for enhanced ontology engineering from datasets. *Information Processing and Management*, 62(3). <https://doi.org/10.1016/j.ipm.2024.104042>